Regresja Liniowa

Uczenie Maszynowe
uczeniemaszynowe@cs.uni.wroc.pl

18.10.2026, 12:00
pracownia

Uwagi ogólne:

- Wszystkie dane dostarczone są w plikach `.csv`.
- Zalecamy, żeby przy rozwiązywaniu zadań nie kopiować całości rozwiązań z modeli językowych. Można jednak zapytać o feedback i dodatkowe materiały na zadany temat.
- Podczas oddawania zadań weryfikacji poddane zostanie zrozumienie poszczególnych etapów zadania i znajomość elementów rozwiązania. Należy mieć przygotowanie środowisko z dostępem do wszystkich danych, tak by móc sprawnie zaimplementować drobne modyfikacje rozwiązań.
- Nie ma konieczności szczegółowo zapisywać odpowiedzi na pytania do dyskusji na pracowni, ale zdecydowanie warto te kwestie przemyśleć – choćby w tramwaju w drodze na zajęcia.

Zadanie 1. [2 pkt]

Czy regresja liniowa jest modelem odpowiednim dla danych `data1.csv`? Jak odpowiednio przygotować dane do modelowania?

1 pkt. Zrób odpowiednie obliczenia i wizualizacje. Zapisz obserwacje i wnioski.

1 pkt. Zaproponuj jak przygotować dane lub przekształcić formułę, by móc do nich użyć modelu regresji liniowej. Rozwiązanie podaj w postaci jednej funckji `preprocess_data(X_train, y_train)`, której działanie powinno być niezmiennicze na permutacje obserwacji w zbiorze uczącym.

Wskazówki:

- Aby wczytać dane możesz użyć funkcji `pd.read_csv()` z biblioteki `pandas`, zwróć uwagę na nagłówek pliku.
- Wykresy możesz zrobić korzystając z bibliotek `matplotlib` lub `seaborn`.
- Żeby dobrać odpowiedni rodzaj wykresu postaw pytanie, na które chcesz poznać odpowiedź. Np. przypomnij sobie jakie są założenia o danych dla modelu regresji liniowej i sprawdź, czy dane spełniają te założenia. Wybierz jakie zmienne zwizualizować na osiach wykresu. Następnie, wybierz typ wykresu (lineplot, scatterplot, histogram, KDEplot, ...).
- Jakiekolwiek obliczenia na pracowni robimy na komputerze, preferowane jest użycie funkcji dostępnych w popularnych bibliotekach.
- Zacznij od opisania co widzisz na wykresie (np. punkty reprezentujące dane układają się w okrąg), czyli obserwacji. Następnie przejdź do wniosków (np. zatem z dużym prawdopodobieństwem, zależność między zmienną na osi X oraz zmienną na osi Y nie jest funkcją).
- Spróbuj zidentyfikować prostą zależność między zmiennymi na osiach X i Y, zapisz równanie tej zależności. Pomoże Ci to zidentyfikować pełne rozwiązanie drugiej części zadania.

Zadanie 2. [3 pkt]

Korzystając z biblioteki `sklearn`, dopasuj do danych `data1.csv` model regresji liniowej oraz sprawdź jego skuteczność, korzystając z błędu średniokwadratowego. Sprawdź, jak użycie przygotowania danych zaproponowanego w Zadaniu 1 wpływa na otrzymane wyniki.

.5 pkt Zaproponuj odpowiedni podział danych. Czy będzie on taki sam przy budowanie pojedynczego modelu jak również w sytuacji, kiedy chcemy wybrać jeden spośród kilku modeli?

.5 pkt Zaproponuj model baseline'owy, czyli prostszy model, który posłuży nam jako punkt odniesienia, czy uzyskane wyniki są akceptowalnej jakości.

.5 pkt Zbuduj model regresji liniowej i model baseline'nowy na rozpatrywanych wariantach danych (po jednym dla surowych danych i danych po preprocessingu).

.5 pkt Przeprowadź ewaluację modeli. Wyniki przedstaw w formie tabeli.

1 pkt Przeprowadź ewaluację modelu na danych udostępnionych w trakcie pracowni. *Ocena tego podpunktu może być zależna od uzyskanych wyników.*

Zadanie 3. [2 pkt]

Użyj danych `advertising.csv`.

.5 pkt Przeprowadź analizę i przygotowanie danych, wzorując się na zadaniach 1 i 2.

.5 kpt "Zbuduj modele regresji liniowej na danych, w których skala zmiennych jest zachowana i na danych znormalizowanych.

.5 pkt Porównaj te dwa modele, zapisz obserwacje i wnioski.

.5 pkt Wskaż najlepszy model do ewaluacji na zbiorze testowym udostępnionym w trakcie ćwiczeń.

Kryteria oceny lub wzorcowe rozwiązanie: TBA

Zadanie 4. [3 pkt]

Użyj danych `data4.csv`.

.5 pkt Przeanalizuj dostarczone dane.

1 pkt Dla podanych danych zbuduj dwa modele: standardową regresję liniową oraz z użyciem regularyzacji w normie L_2 z **odpowiednim** hiperparametrem λ_2.

1 pkt Porównaj otrzymane parametry regresji oraz skuteczność na zbiorze testowym. Który model zadziałał lepiej i dlaczego (podaj obserwacje i teoretyczne uzasadnienie)?

.5 pkt Sprawdź skuteczność modelu na udostępnionym w trakcie zajęć zbiorze danych.

Dyskusja na pracownię

Jakie techniki i dobre praktyki poznaliście / zastosowaliście rozwiązując tę listę? Które z nich dotyczą regresji liniowej, a które będą miały przełożenie także na inne tematy/działy uczenia maszynowego?